

Opis projektu

Łukasz Bogaczyk 155278

1 Opis rzeczywistego problemu

Celem projektu jest stworzenie systemu sztucznej inteligencji, który będzie w stanie klasyfikować gatunki kwiatów na podstawie zdjęć z wysoką dokładnością. Zagadnienie to jest istotne, ponieważ znajduje zastosowanie w takich dziedzinach jak rolnictwo, botanika czy ochrona środowiska. Dane wejściowe to wartości RGB każdego piksela obrazu, które reprezentują kolory i cechy wizualne zdjęcia. Zagadnienia związane z sztuczną inteligencją, które wystąpią w projekcie to głębokie uczenie i przetwarzanie obrazów.

2 State of art

2.1

Jednym z podejść do klasyfikacji kwiatów są tradycyjne metody uczenia maszynowego, takie jak Support Vector Machine (SVM) i Random Forest (RF). Przykładem jest system zaprezentowany w pracy "An Automatic Flower Classification Approach Using Machine Learning Algorithms", w którym wykorzystano technikę Scale Invariant Feature Transform (SIFT) oraz Segmentation-based Fractal Texture Analysis (SFTA) do wydobywania cech z obrazów kwiatów. Po ekstrakcji cech, obrazy zostały sklasyfikowane przy użyciu SVM oraz RF. Wyniki pokazały, że SVM uzyskał wyższą dokładność przy wykorzystaniu cech SIFT, podczas gdy RF sprawdzał się lepiej w połączeniu z SFTA. Mocną stroną tego podejścia, jest to, że dobrze radzi sobie z małymi zbiorami danych i nie wymaga dużego obciążenia obliczeniowego, ale za to wymaga ręcznej ekstrakcji cech z obrazu.

2.2

Inną metodą są konwolucyjne sieci neuronowe (CNN), które umożliwiają automatyczne wydobywanie cech z obrazu. Przykładem może być badanie, w

którym zastosowano CNN do klasyfikacji 102 gatunków kwiatów, korzystając z zestawu 25000 zdjęć. Takie podejście przyczyniło się do znacznego wzrostu dokładności klasyfikacji w porównaniu do metod tradycyjnych. Słabą stroną tego podejścia jest duże wymaganie mocy obliczeniowej.

2.3

Innym podejściem jest wykorzystanie hybrydowych technik klasyfikacji, takich jak Multiple Kernel Learning (MKL) w połączeniu z SVM. W jednej z analiz wprowadzono metodę MKL - SVM, w której zastosowano różne jądra do analizy różnych właściwości obrazu, takich jak kolor czy kształt. Połączenie tych cech przyczyniła się do poprawy dokładności klasyfikacji kwiatów w porównaniu do jednoskalowych modeli uczenia maszynowego. Trudność tej metody polega na zastosowaniu bardziej zaawansowanych algorytmów co zwiększa złożoność obliczeniową modelu.

2.4 Opis wybranej koncepcji

Koncepcja rozwiązania problemu identyfikacji gatunków kwiatów będzie opierała się na zastosowaniu konwolucyjnej sieci neuronowej (CNN) do klasyfikacji obrazów pięciu gatunków kwiatów: stokrotek, mleczy, róż, słoneczników i tulipanów. Dane wejściowe składają się z obrazów zapisanych na dysku, które zostały pobrane ze strony udostępniającej gotowe zbiory danych do uczenia maszynowego. Po wczytaniu obrazu są losowo przetasowywane, co poprawia generalizację modelu. Aby zwiększyć odporność modelu na niewielkie zmiany w danych wejściowych, niektóre obrazy zostaną losowo odbite wzdłuż osi y oraz obrócone o maksymalnie 5%. Dodatkowo, wszystkie wartości pikseli są normalizowane poprzez podzielenie przez 255, co pomoże w trenowaniu sieci neuronowej. Dane są następnie podzielone na trzy zestawy: treningowy (70% całego zbioru), walidacyjny (20%) oraz testowy (10%). Zaimplementowana architektura modelu będzie składała się z kilku warstw konwolucyjnych z funkcją aktywacji ReLU, które umożliwiają wykrywanie cech charakterystycznych obrazów, takich jak krawędzie i tekstury. Po każdej warstwie konwolucyjnej zastosuję operację MaxPooling, co pozwoli na redukcję wymiaru obrazu i zwiększy efektywność obliczeniową modelu. Następnie dane zostaną spłaszczane przy użyciu warstwy Flatten, po czym przejdą przez warstwę Dense z 256 neuronami i funkcją aktywacji ReLU. Aby ograniczyć możliwość przeuczenia modelu, dodam warstwę Dropout, która losowo dezaktywuje część neuronów podczas treningu. Ostateczna warstwa modelu zawiera pięć neuronów i funkcję aktywacji softmax, co pozwala na uzyskanie prawdopodobieństwa, że obraz należy do danej klasy obrazów(kwiatów). Proce-

dura testowania rozwiązania będzie polegała na analizie wyników uzyskanych przez model oraz wykresów przedstawiających krzywe straty i dokładności. Dzięki temu możliwe będzie ocenienie, czy model działa poprawnie i czy wymaga dalszej optymalizacji. Problemy, które mogą wystąpić, to przeuczenie modelu, wynikające z nadmiernego dopasowania do danych treningowych, a także niewystarczająca ilość danych. Całe rozwiązanie jest oparte na dobrze znanych technikach uczenia maszynowego, co sprawia, że nie powinno być problemu w realizacji tego projektu w rzeczywistym świecie.

3 Bibliografia

- <https://ieeexplore.ieee.org/abstract/document/6968612>
- https://www.researchgate.net/profile/Sanskriti-Patel-2/publication/344249077_Flower_Identification_and_Classification_using_Computer_Vision_and_Machine_Learning_Techniques/links/5f608a13a6fdcc1164133617/Flower-Identification-and-Classification-using-Computer-Vision-and-Machine-pdf
- <https://www.kaggle.com/datasets/alxmamaev/flowers-recognition>
- https://www.tensorflow.org/api_docs/python/tf/
- <https://www.geeksforgeeks.org/what-are-the-possible-approaches-to-fixing-ov>
- <https://stackoverflow.com/questions/36139980/prevention-of-overfitting-in-c>
- https://www.tensorflow.org/api_docs/python/tf/